Prévoir le nombre de vélos disponibles dans les stations de Toulouse

Compte rendu du projet de statistique

UE L2 Projet de Statistique CMI OSIA – Année 2026-2027

Baptiste du Reau & Aïdan Caillot

1. Les données et leur exploration

Pour ce projet, nous avons travaillé sur les stations de vélos en libre-service de Toulouse. Nous avions trois fichiers : la liste des stations (nom, identifiant, longitude et latitude), un historique d'entraînement et un historique de test. Pour chaque station et toutes les 15 minutes, on connaît le nombre de vélos disponibles (*bikes*) et le nombre de places libres (*stands*).

Premières observations

• Il n'y a **aucune valeur manquante** dans l'historique.

• La liste des stations contient **63 stations de plus** que les historiques d'entraînement et de test. Ces stations n'ont donc pas de mesures.

• Le nombre de mesures change beaucoup d'une station à l'autre. La plupart des stations ont entre 20 000 et 70 000 observations, mais certaines en ont presque aucune et d'autres en ont près de 100 000 (figure 1).

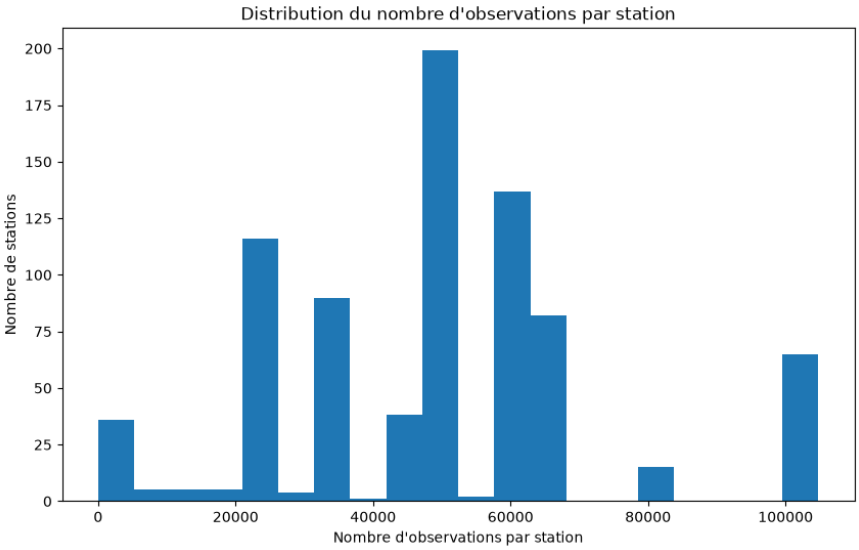


Figure 1 – Nombre d'observations par station

Période des mesures

Les stations n'ont pas toutes été mesurées sur la même période. Environ la moitié des stations commence à partir de septembre 2023 et l'autre moitié entre septembre et décembre 2024. Pour la fin, plus des deux tiers des stations sont suivies jusqu'en juillet-août 2026 et quelques-unes s'arrêtent dès janvier 2025 (figure 2).

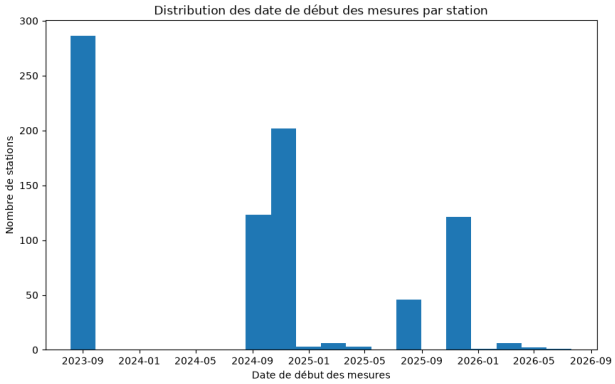


Figure 2a – Dates de début des mesures

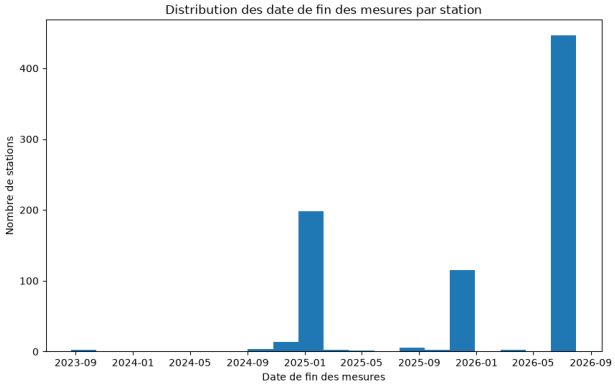


Figure 2b – Dates de fin des mesures

Statistiques de base par station

Pour chaque station, nous avons calculé le minimum, les quartiles, la médiane, la moyenne et le maximum du nombre de vélos, puis la même chose pour les places libres. Nous avons ensuite comparé les stations entre elles avec des boîtes à moustaches (figure 3).

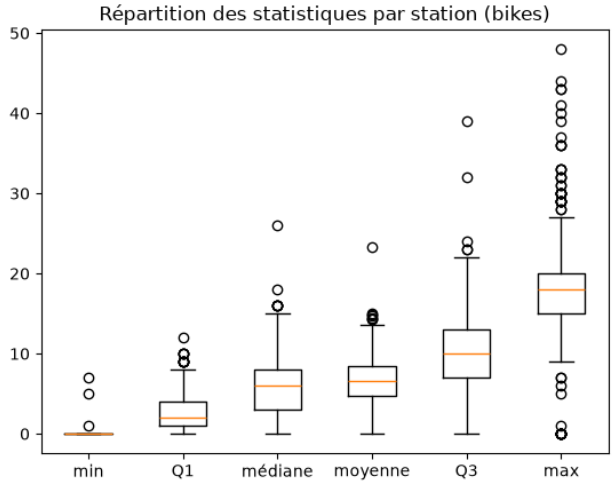


Figure 3a – Statistiques par station : vélos disponibles

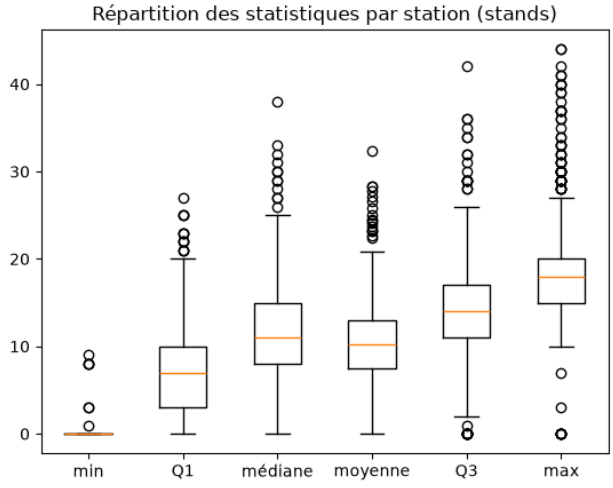
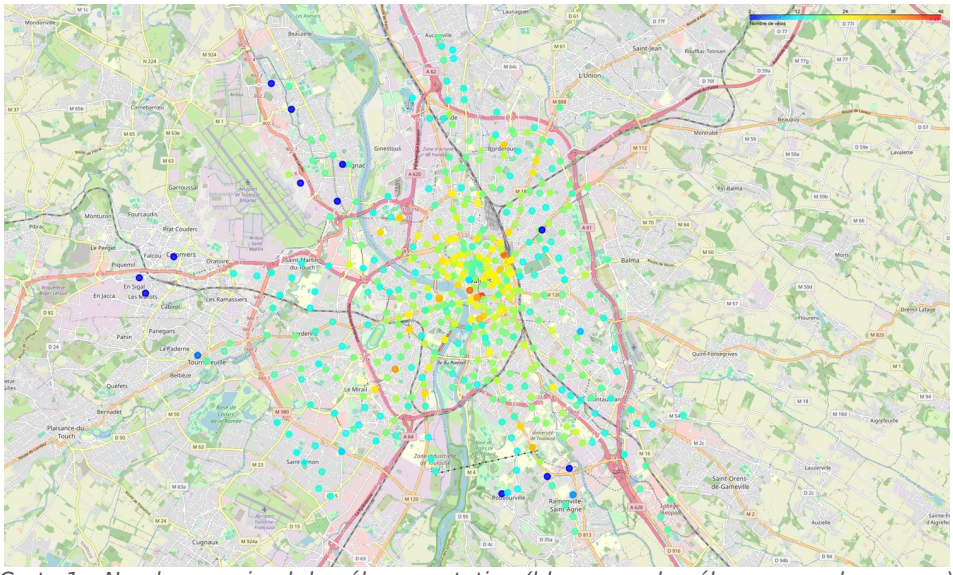


Figure 3b – Statistiques par station : places libres

Ce que l'on observe. Pour les vélos, presque toutes les stations sont dans les boîtes, donc leurs statistiques sont assez proches. Seul le maximum a des valeurs plus éloignées (les ronds) : quelques stations sont très différentes des autres. Pour les places libres, c'est pareil, mais il y a plus de valeurs éloignées.

Nous avons aussi fait des cartes où chaque station est un point coloré, du bleu au rouge. La première montre le nombre maximal de vélos par station. Les autres montrent le taux de remplissage à différentes heures (voir partie suivante).

La carte 1 montre le nombre maximal de vélos de chaque station. Les stations du centre-ville ont les maximums les plus élevés (jusqu'à environ 48 vélos, en orange et rouge). Les stations plus éloignées du centre ont des maximums plus faibles (en bleu et en vert).



Carte 1 – Nombre maximal de vélos par station (bleu : peu de vélos, rouge : beaucoup)

2. Le remplissage des stations au cours de la journée

Nous avons calculé le nombre moyen de vélos disponibles pour chaque quart d'heure de la journée. Nous l'avons fait d'abord pour une station du centre-ville, « Poids de l'Huile », puis pour toutes les stations ensemble.

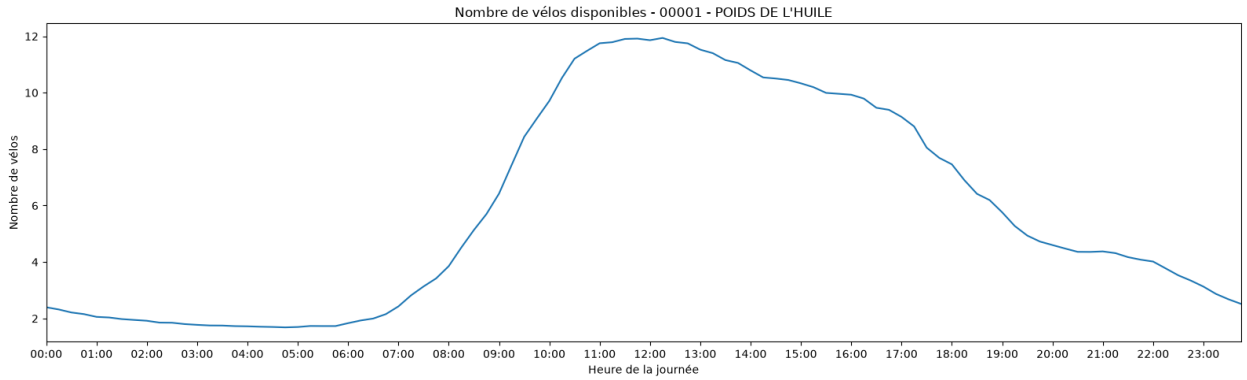


Figure 4 – Nombre moyen de vélos disponibles dans la journée, station « 00001 – Poids de l'Huile »

Cette station est presque vide la nuit (environ 2 vélos). Elle se remplit à partir de 7 h, atteint environ 12 vélos vers midi, puis se vide peu à peu en fin de journée. On peut penser que les gens viennent en centre-ville pour travailler, puis prennent un vélo pour rentrer chez eux.

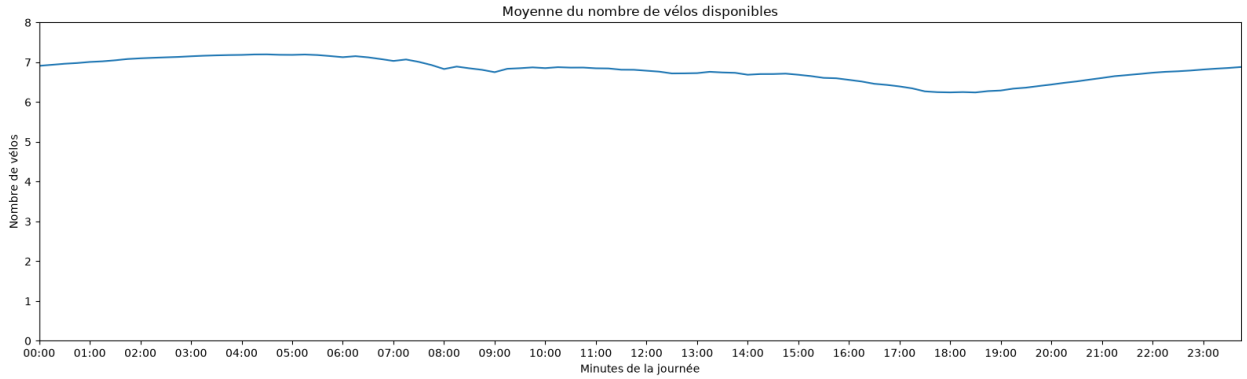


Figure 5 – Nombre moyen de vélos disponibles, toutes stations confondues

Pour l’ensemble des stations, le nombre moyen de vélos reste à peu près constant toute la journée. On voit quand même de petits creux vers 8 h et entre 18 h et 19 h. Ce sont les heures où l’on commence et où l’on finit le travail : beaucoup de vélos sont pris en même temps.

Premier quartile, médiane et troisième quartile

Nous avons refait la même courbe avec le premier quartile (25 % des stations sont en dessous), la médiane et le troisième quartile (25 % des stations sont au-dessus).

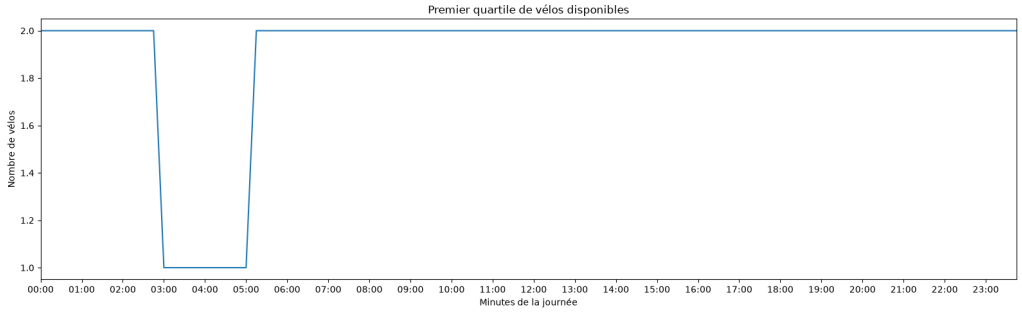


Figure 6a – Premier quartile du nombre de vélos disponibles

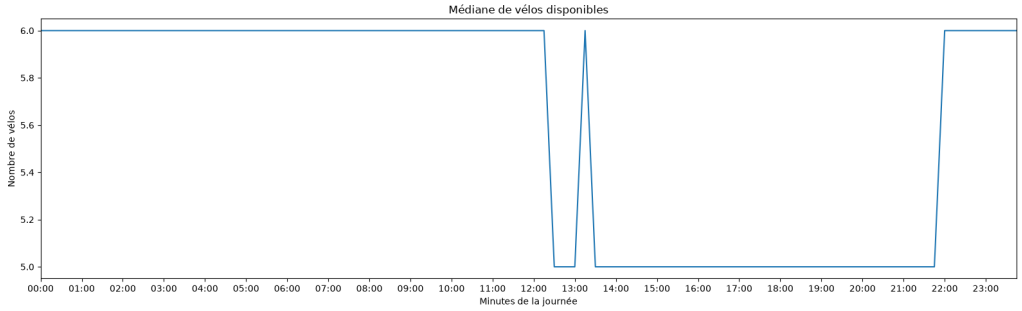


Figure 6b – Médiane du nombre de vélos disponibles

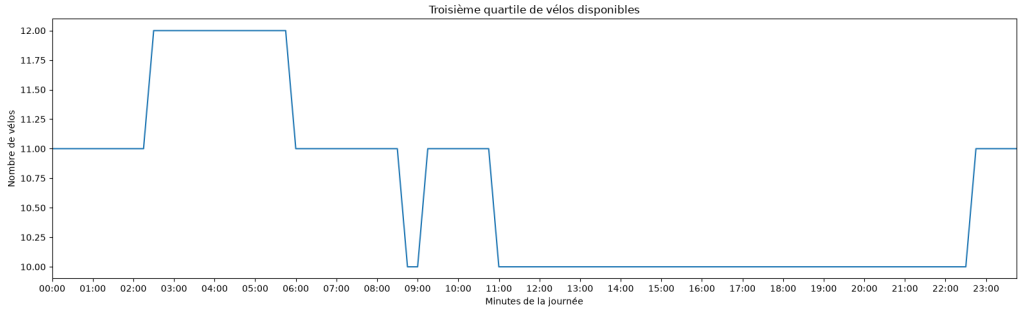


Figure 6c – Troisième quartile du nombre de vélos disponibles

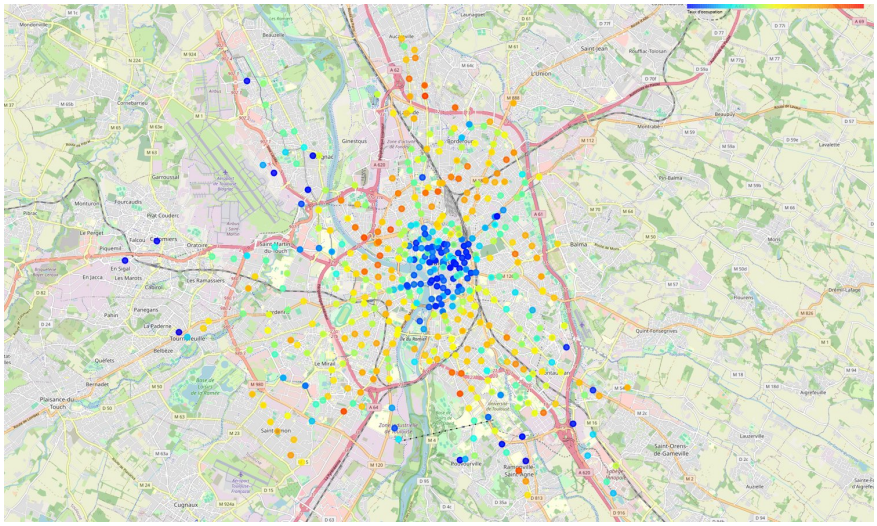
• **Premier quartile :** entre 3 h et 5 h du matin, un quart des stations a 1 vélo ou moins. Le reste du temps, c’est 2 vélos ou moins.
• **Médiane :** de 12 h à 22 h, la moitié des stations a 5 vélos ou moins. Le reste du temps, c’est 6.
• **Troisième quartile :** entre 2 h et 6 h du matin, un quart des stations a 12 vélos ou plus. Entre 23 h et 2 h et entre 6 h et 11 h, c’est 11. Le reste du temps, c’est 10.

Où sont les vélos selon l’heure ?

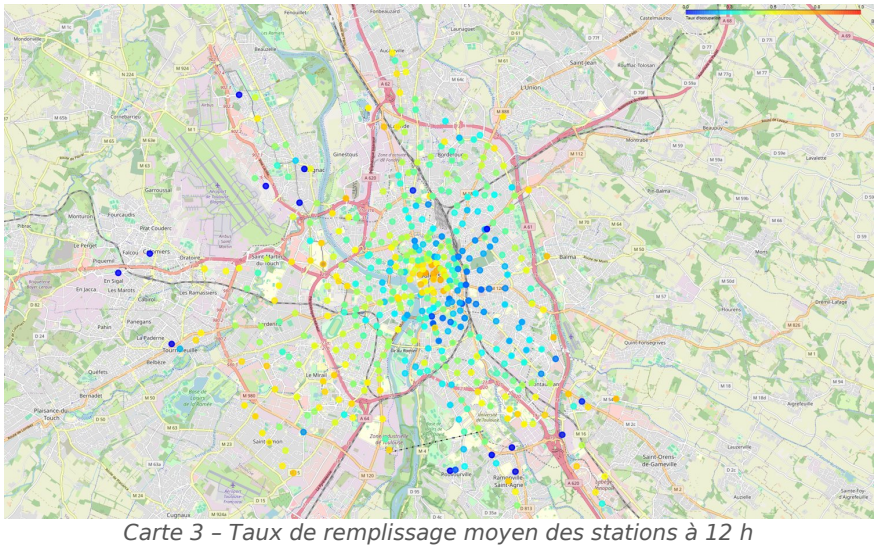
Nous avons calculé le **taux de remplissage** de chaque station, c’est-à-dire le nombre de vélos divisé par le nombre total d’emplacements. Nous l’avons ensuite affiché sur des cartes à trois heures différentes (5 h, 12 h et 23 h). Voici ce que l’on observe :

Heure	Centre-ville	Quartiers résidentiels
5 h	Stations presque vides	Stations bien remplies (tout le monde dort)
12 h	Stations pleines	Stations presque vides (tout le monde travaille)
23 h	Le centre commence à se vider	Les stations se remplissent

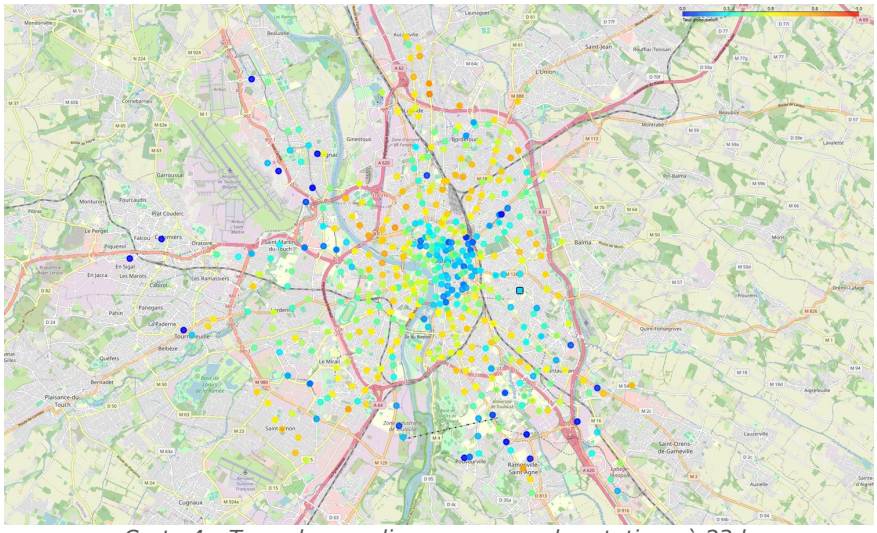
Les cartes 2, 3 et 4 montrent ces trois moments. Plus la couleur est bleue, plus la station est vide. Plus elle est rouge, plus la station est pleine.



Carte 2 – Taux de remplissage moyen des stations à 5 h



Carte 3 – Taux de remplissage moyen des stations à 12 h



Carte 4 – Taux de remplissage moyen des stations à 23 h

On voit donc que l'heure et l'endroit où se trouve la station jouent un grand rôle dans le remplissage. Nous avons utilisé ces deux informations dans nos méthodes de prévision.

3. Les stations renommées

En regardant les coordonnées GPS, nous avons vu que **296 emplacements ont plusieurs noms** : 223 ont deux noms, 62 en ont trois et 11 en ont quatre. Ce sont en fait des stations qui ont été renommées avec le temps, donc plusieurs noms peuvent désigner la même station.

Cela explique ce que l'on voyait sur la figure 1. Une station gardée sur toute la période a environ 100 000 mesures. Une station renommée une fois apparaît sous deux noms, avec environ 50 000 mesures chacun. Une station renommée deux ou trois fois apparaît avec 20 000 à 30 000 mesures par nom. Si on traite chaque nom comme une station différente, l'historique d'une même station est coupé en morceaux. Nous avons utilisé cette remarque dans la méthode 3.

4. Les trois méthodes de prévision

Le but est de prévoir, pour chaque station, le nombre de vélos disponibles à **8 horaires différents : dans 15 min, 30 min, et ainsi de suite jusqu'à 2 h**. Pour tester chaque méthode, nous l'entraînons sur les données de validation et nous la testons sur les dernières valeurs connues, pour voir si les prévisions sont proches de la réalité. Ensuite, nous ré-entraînons la méthode sur toutes les données pour faire les vraies prédictions.

Méthode 1 – La moyenne par quart d'heure

Principe. C'est la méthode la plus simple. Pour prévoir le nombre de vélos d'une station à une heure donnée, on prend la **moyenne** du nombre de vélos de cette station au même quart d'heure dans l'historique. Par exemple, pour prévoir à 8 h 45, on regarde le nombre moyen de vélos à 8 h 45.

Si on n'a pas de donnée. Quand une station n'a jamais été mesurée à ce quart d'heure, on prend une moyenne moins précise : d'abord la moyenne de la station à cette heure, puis la moyenne de la station sur toute la journée, puis la moyenne de toutes les stations (figure 7).

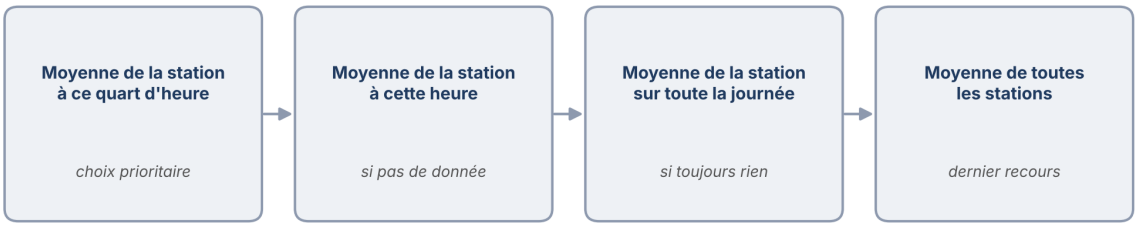


Figure 7 – Ordre des moyennes utilisées quand il manque des données

Avantages et défauts. Cette méthode est rapide et suit bien le rythme de la journée vu plus haut. Par contre, elle ne regarde pas combien il y a de vélos dans la station en ce moment, et elle ne tient pas compte du jour de la semaine, des vacances ou des jours fériés.

Méthode 2 – La régression linéaire

Principe. La régression linéaire prédit une valeur à partir de plusieurs informations, en donnant à chacune un poids. Nous créons **un modèle différent pour chaque horaire** (15 min, 30 min, etc.). À partir de la situation d'une station à un instant t, il prévoit le nombre de vélos plus tard. Il apprend avec toutes les situations de l'historique dont on connaît la suite.

Les informations données au modèle (17 en tout) :

Type	Informations utilisées	Pourquoi
Situation actuelle	Nombre de vélos à l'instant t, nombre total d'emplacements, taux de remplissage	Le futur proche dépend beaucoup de ce qu'il y a maintenant
Date et heure	Année, mois, jour de la semaine, week-end, heure, minute	L'utilisation change selon le moment (figures 4 à 6)
Jours spéciaux	Vacances scolaires (zone C, celle de Toulouse), jours fériés	On ne se déplace pas pareil quand on ne travaille pas
Position	Longitude et latitude de la station	Centre-ville et quartiers résidentiels se remplissent à l'inverse

Deux détails importants. (1) Pour le mois, le jour, l'heure et la minute, nous avons utilisé un sinus et un cosinus. Cela permet au modèle de comprendre que 23 h est juste avant 0 h, alors que les nombres 23 et 0 sont très éloignés. (2) Nous avons limité les prédictions : elles ne peuvent pas être négatives ni dépasser le nombre total d'emplacements de la station. Nous les arrondissons ensuite à un nombre entier.

Avantages et défauts. Cette méthode utilise le nombre de vélos actuel, ce qui aide beaucoup pour les prévisions proches. Mais comme elle est linéaire, elle ne peut pas décrire des effets trop compliqués.

Méthode 3 – La régression linéaire avec nettoyage des données

Principe. Nous gardons la même régression que pour la méthode 2, mais nous améliorons d'abord les données. Il y a trois étapes (figure 8) :

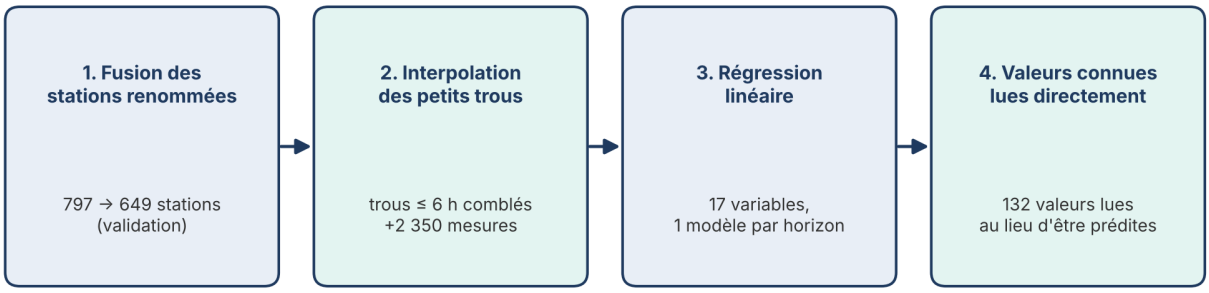


Figure 8 – Les étapes de la méthode 3

1. Regrouper les stations renommées. Les stations qui ont exactement les mêmes coordonnées sont regroupées sous leur premier nom. On le fait seulement si leurs périodes de mesure ne se chevauchent pas de plus de 6 heures, sinon ce seraient deux vraies stations voisines. Avec les données de validation, on passe ainsi de **797 à 649 stations** (de 800 à 650 avec toutes les données). L'historique d'une station n'est plus coupé en morceaux.

2. Combler les petits trous. Quand il manque quelques mesures à la suite (moins de 6 heures), nous les remplaçons par des valeurs sur une droite entre la dernière mesure avant le trou et la première après. C'est ce qu'on appelle une interpolation linéaire. Cela ajoute environ 2 350 mesures aux 40 006 230 mesures de départ. Nous ne comblons pas les trous plus longs, car une droite serait trop peu réaliste.

3. Utiliser les valeurs déjà connues. Si l'instant à prévoir est déjà dans l'historique d'entraînement (132 cas par horaire en validation, 136 avec toutes les données), on recopie directement la vraie valeur. La régression ne sert que pour les instants qu'on ne connaît pas.

Avantages et défauts. Chaque étape corrige un problème des données trouvé pendant l'exploration : stations renommées et mesures manquantes. L'amélioration reste petite, car ces cas ne concernent qu'une petite partie des prédictions.

5. Comparaison des méthodes et conclusion

Méthode	Idée principale	Ce qui est pris en compte
1 – Moyenne par quart d'heure	Moyenne de la station au même moment de la journée	La station et l'heure
2 – Régression linéaire	Un modèle par horaire, avec 17 informations	Situation actuelle, date, heure, jours spéciaux et position
3 – Régression + nettoyage	Même modèle, avec des données améliorées	Idem, avec stations regroupées, trous comblés et valeurs connues

Conclusion

Pendant ce projet, nous avons d'abord étudié les données. Nous avons vu que les stations suivent un rythme dans la journée : le centre-ville se remplit le jour et se vide le soir, et les quartiers résidentiels font l'inverse. Nous avons aussi vu que certaines stations ont été renommées, ce qui coupe leur historique en plusieurs morceaux. Ensuite, nous avons utilisé trois méthodes de prévision de plus en plus complètes. La première utilise seulement la moyenne par quart d'heure. La deuxième utilise une régression linéaire avec le nombre de vélos actuel, la date, l'heure et la position de la station. La troisième garde cette régression, mais nettoie d'abord les données en regroupant les stations renommées, en comblant les petits trous et en utilisant les valeurs déjà connues.

Pour la suite, nous envisageons de passer à des **modèles non linéaires**, car une régression linéaire ne peut pas décrire des effets trop compliqués. Nous pensons tester les modèles suivants : RegressionPolynomiale, ArbreDecision, ForetAleatoire, GradientBoosting, HistGradientBoosting, XGBoost, LightGBM et MLPRegressor. Nous voulons voir si ces modèles permettent de mieux prévoir le nombre de vélos.